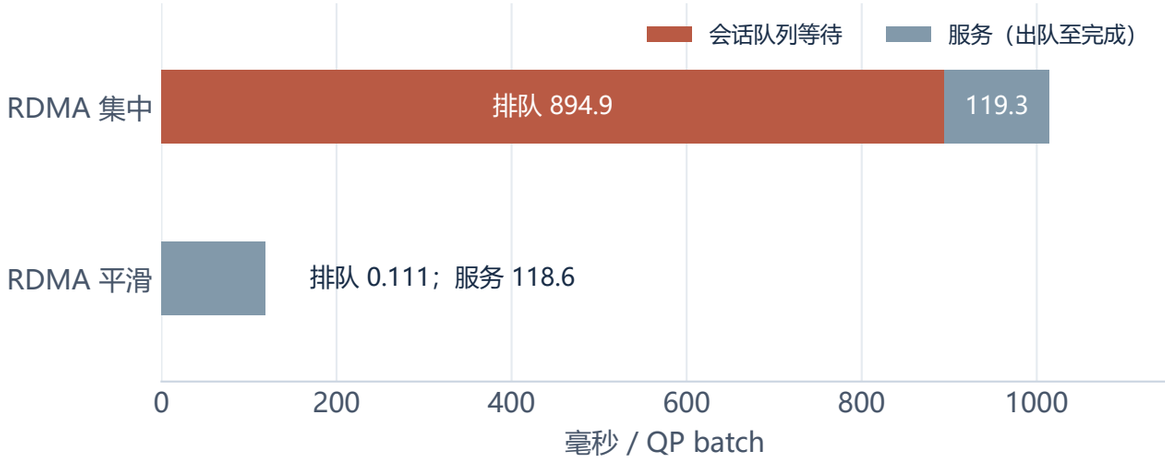
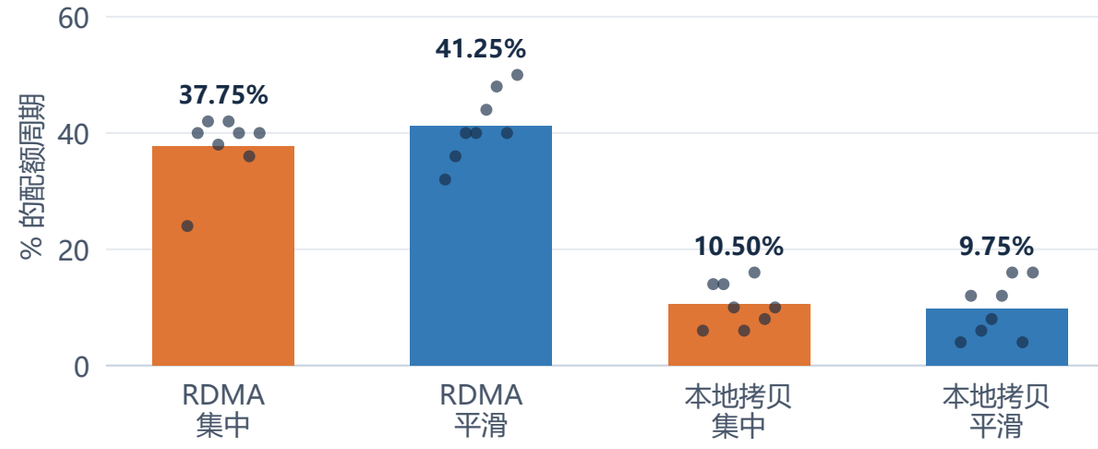
差异从哪里来：传输排队、CPU 配额与已有解码

同一轮测量 · 前景软件限速关闭 · 后台周期报告均值约 89–90 Gb/s · 共同事件窗：整批缓存具备传输资格后的 4 秒

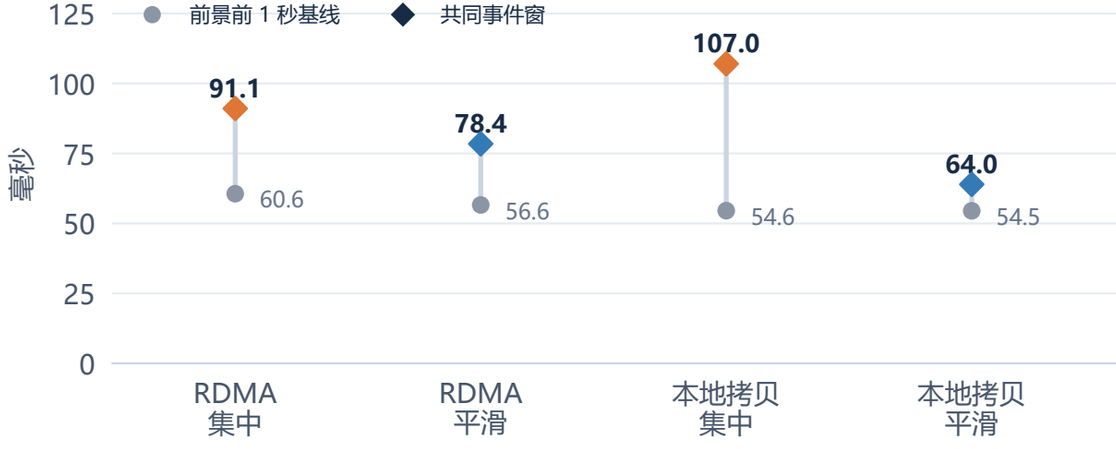
A 原生 QP batch 的平均耗时



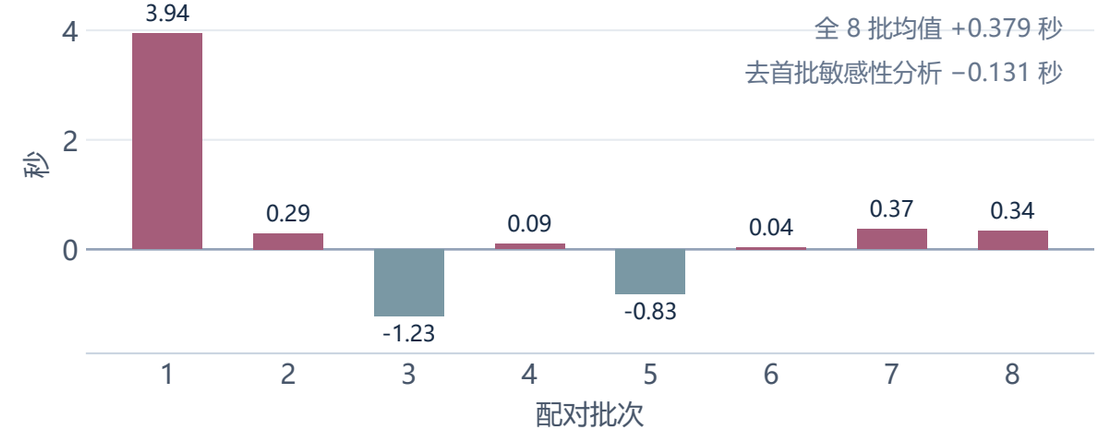
B CPU 配额周期中发生限流的比例



C 已有解码：客户端 SSE 消息间隔 p99



D RDMA 相对本地的额外 TTFT 差距



A：QP batch 与逻辑请求的统计对象不同。B：点为各批次；限流周期比例不等于损失的墙钟时间比例。

C：SSE 消息可含多个 token，因此不是严格 TPOT。D：(RDMA 集中−平滑)−(本地集中−平滑)，用于检查网络相关增量的稳定性。